



SENA - Servicio Nacional de Aprendizaje

Análisis Exploratorio de Datos en Python

Evidencia AA4-EV01: Informe de resultados obtenidos del análisis de datos exploratorio realizado al caso de estudio

Presentado por:

Liliana Andrea Díaz Sippli

Presentado a:

Instructor Luis Alberto Galicia Guerrero

Barranquilla, Colombia

24/11/2025

Introducción

El presente informe contiene el Análisis Exploratorio de Datos (EDA) de un conjunto de datos que contiene información de clientes de una aseguradora, con el objetivo principal de identificar los factores demográficos y de salud que influyen de manera más significativa en el Valor del Seguro. El análisis se centra en determinar si las personas fumadoras representan el mayor potencial de ingreso para la venta de seguros, identificar la edad poblacional en la que se debe concentrar la estrategia comercial teniendo en cuenta el mayor ingreso potencial, y establecer cuál es la región con mayor potencial de venta de seguros considerando la contribución a los ingresos. Para responder a estos objetivos, el EDA examina la distribución de variables clave como la Edad, el IMC (Índice de Masa Corporal), el Número de Hijos, Sexo y Región, y procede a la visualización de las interacciones bivariadas y multivariadas.

Análisis Exploratorio de Datos en Python de clientes de aseguradora

El análisis inicia con la importación de las librerías necesarias para el tratamiento y visualización de datos. Posteriormente, se realiza la carga del dataset original, seguido de una revisión inicial de su estructura, tipos de datos y contenido, lo que permite verificar que la información se encuentra en el estado adecuado para continuar con el proceso de exploración.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

```
df = pd.read_csv('DatosSeguros.csv')
df
```

```
: df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1350 entries, 0 to 1349
Data columns (total 7 columns):
 #   Column        Non-Null Count  Dtype  
---  --
 0   edad          1349 non-null   float64
 1   sexo          1349 non-null   object  
 2   imc           1347 non-null   float64
 3   hijos         1349 non-null   float64
 4   fumador       1347 non-null   object  
 5   region        1349 non-null   object  
 6   valor_seguro  1349 non-null   float64
dtypes: float64(4), object(3)
memory usage: 74.0+ KB
```

Ahora nos enfocamos en verificar si hay nulos y duplicados. Hay muy pocos de ambos (11 y 12 respectivamente), por lo que simplemente se eliminan. Luego, verificamos uniformidad en el dataset:

```
df.isnull().sum()
```

```
edad      1
sexo      1
imc       3
hijos     1
fumador   3
region    1
valor_seguro 1
dtype: int64
```

```
df=df.dropna()
```

```
: print(df[df.duplicated()])
```

	edad	sexo	imc	hijos	fumador	region	valor_seguro
1	19.0	F	27.900	0.0	yes	Caribe	16884.92400
2	19.0	F	27.900	0.0	yes	Caribe	16884.92400
583	19.0	M	30.590	0.0	no	Antioquia	1639.56310
1229	38.0	M	16.815	2.0	no	Boyaca	6640.54485
1230	38.0	M	16.815	2.0	no	Boyaca	6640.54485
1231	38.0	M	16.815	2.0	no	Boyaca	6640.54485
1237	52.0	M	34.485	3.0	yes	Antioquia	60021.39897
1238	20.0	F	21.800	0.0	yes	Caribe	20167.33603
1341	19.0	F	27.900	0.0	yes	Caribe	16884.92400
1342	19.0	F	27.900	0.0	yes	Caribe	16884.92400
1346	19.0	F	27.900	0.0	yes	Caribe	16884.92400
1349	19.0	F	27.900	0.0	yes	Caribe	16884.92400

```
: df=df.drop_duplicates()
```

```
: df.info()

<class 'pandas.core.frame.DataFrame'>
Index: 1333 entries, 0 to 1348
Data columns (total 7 columns):
 #   Column        Non-Null Count  Dtype  
---  --
 0   edad          1333 non-null   float64
 1   sexo          1333 non-null   object  
 2   imc           1333 non-null   float64
 3   hijos         1333 non-null   float64
 4   fumador       1333 non-null   object  
 5   region        1333 non-null   object  
 6   valor_seguro  1333 non-null   float64
dtypes: float64(4), object(3)
memory usage: 83.3+ KB
```

Ordenamos el dataset por edad para verificar el número mínimo y máximo de esta. Como se observa son 18 y 64, respectivamente.

```
[4]: edad = df.sort_values('edad')
     edad.head(10)
```

[4]:	edad	sexo	imc	hijos	fumador	region	valor_seguro
1097	18.0	F	31.350	4.0	no	Boyaca	4561.18850
59	18.0	M	31.680	2.0	yes	Cundinamarca	34303.16720
1251	18.0	M	33.330	0.0	no	Cundinamarca	1135.94070
297	18.0	M	22.990	0.0	no	Boyaca	1704.56810
1255	18.0	F	39.820	0.0	no	Cundinamarca	1633.96180
944	18.0	F	40.185	0.0	no	Boyaca	2217.46915
1152	18.0	F	30.305	0.0	no	Boyaca	2203.73595
665	18.0	M	33.660	0.0	no	Cundinamarca	1136.39940
52	18.0	F	35.625	0.0	no	Boyaca	2211.13075
650	18.0	M	28.500	0.0	no	Boyaca	1712.22700

```
edad = df.sort_values('edad', ascending = False)
edad.head(10)
```

	edad	sexo	imc	hijos	fumador	region	valor_seguro
422	64.0	M	33.880	0.0	yes	Cundinamarca	46889.26120
754	64.0	M	37.905	0.0	no	Antioquia	14210.53595
404	64.0	F	32.965	0.0	no	Antioquia	14692.66935
420	64.0	M	39.160	1.0	no	Cundinamarca	14418.28040
380	64.0	F	30.115	3.0	no	Antioquia	16455.70785
1053	64.0	M	26.410	0.0	no	Boyaca	14394.55790
827	64.0	F	31.825	2.0	no	Boyaca	16069.08475
1248	64.0	M	36.960	2.0	yes	Cundinamarca	49577.66240
803	64.0	F	35.970	0.0	no	Cundinamarca	14313.84630
337	64.0	M	34.500	0.0	no	Caribe	13822.80300

Luego, asignamos rangos de edad por intervalos. Esto lo necesitaremos para el análisis:

```
rangos = [17, 28, 38, 48, 58, 68]
nombrerango = ['A', 'B', 'C', 'D', 'E']
```

```
df['Rango_Edad'] = pd.cut(df['edad'], rangos, labels = nombrerango)
```

Verificamos cuantas personas hay por cada rango de edad:

```
df.groupby(['Rango_Edad']).size()
```

```
C:\Users\USER\AppData\Local\Temp\ip
d=False to retain current behavior
df.groupby(['Rango_Edad']).size()
```

```
Rango_Edad
A      389
B      259
C      273
D      274
E      138
dtype: int64
```

También, verificamos datos estadísticos del dataset:

```
df.describe()
```

	edad	imc	hijos	valor_seguro
count	1333.000000	1333.000000	1333.000000	1333.000000
mean	39.195049	30.652097	1.092273	13261.908454
std	14.052008	6.097609	1.205484	12093.507648
min	18.000000	15.960000	0.000000	1121.873900
25%	27.000000	26.220000	0.000000	4738.268200
50%	39.000000	30.360000	1.000000	9377.904700
75%	51.000000	34.675000	2.000000	16657.717450
max	64.000000	53.130000	5.000000	63770.428010


```
df.describe(include='object')
```

	sexo	fumador	region
count	1333	1333	1333
unique	2	2	4
top	M	no	Cundinamarca
freq	672	1060	362

Ahora sí, pasamos al EDA: las preguntas planteadas son: ¿Las personas fumadoras representan el mayor potencial para venta de seguros?, ¿Cuál es la edad poblacional en la que se debe concentrar la estrategia comercial teniendo en cuenta el mayor ingreso?, ¿Cuál es la región con mayor potencial de venta de seguros teniendo en cuenta los ingresos?

Para resolverlas, este análisis se divide en Univariado, Bivariado y Multivariado.

Análisis Univariado: realizamos histogramas para las variables numéricas




De estos histogramas se concluye lo siguiente:

Variable	Conclusión
edad	Hay mayor concentración entre 18 y 25 años, lo que explica la primera barra más alta. Desde los 30 hasta los 60, la distribución se mantiene variada, pero sin extremos.
imc	El mayor número de personas está entre 25 y 35, categorizado como sobrepeso según la OMS.
hijos	La categoría 0 hijos es la más frecuente
valor_seguro	El costo del seguro varía significativamente, pero la mayoría de personas paga tarifas relativamente bajas. Sin embargo, existen casos especiales con costos muy elevados.

Otros análisis univariados son:


```
1]: fumadores = df['fumador'].value_counts()
etiquetas = fumadores.index
colors = sns.color_palette("hls")
plt.title('Distribución porcentual de fumadores')
plt.pie(fumadores, labels = etiquetas, colors = colors, autopct='%0.1f%%')
plt.show()
```

Distribución porcentual de fumadores



```
]: total_hijos = df['hijos'].groupby(df['hijos']).count()
etiquetas = total_hijos.index
colors = sns.color_palette("hls")
plt.title('Total de hijos')
plt.pie(total_hijos, labels = etiquetas, colors = colors, autopct='%0.1f%%')
plt.show()
```


Total de hijos



```
[24]: total_rango_edad = df['Rango_Edad'].groupby(df['Rango_Edad']).count()
labels = total_rango_edad.index
colors = sns.color_palette("hls")

plt.pie(total_rango_edad, labels = labels, colors = colors, autopct='%0.1f%%')
plt.title('Rangos de edad')
plt.savefig('circular.png')
plt.show()
```

Rangos de edad



Del análisis a estas variables podemos concluir que:

Gráfico	Conclusión
Distribución porcentual de fumadores	La mayor cantidad de clientes no son fumadores (el 80 %).
Rangos de edad	El rango de edad A representa cerca del 30 % del total de registros.
Total de hijos	La categoría 0 hijos es la más frecuente (el 43 % de clientes no tiene hijos).

Análisis Bivariado: se compara *valor_seguro* contra *fumador*. Se hace un conteo de clientes por *region* y *sexo*.

```
23]: Fumador_seguro = sns.boxplot(x=df['fumador'], y=df['valor_seguro'], palette = sns.color_palette("hls"))
plt.title('Valor seguro contra fumador')
plt.xlabel('Fumador')
plt.ylabel('Valor Seguro')
plt.savefig('boxplot.png')
```


C:\Users\USER\AppData\Local\Temp\ipykernel_227544\1405800258.py:1: FutureWarning: Passing 'palette' without assigning 'hue' is deprecated and will be removed in v0.14.0. Assign the 'x' variable to 'hue' to ensure consistent behavior across versions.

Fumador_seguro = sns.boxplot(x=df['fumador'], y=df['valor_seguro'], palette = sns.color_palette("hls"))

C:\Users\USER\AppData\Local\Temp\ipykernel_227544\1405800258.py:1: UserWarning: The palette list has more than 10 entries, which may not be supported by all backends.


Fumador_seguro = sns.boxplot(x=df['fumador'], y=df['valor_seguro'], palette = sns.color_palette("hls"))

Valor seguro contra fumador



```
6]: fuma_seg_pc = df.groupby('fumador')['valor_seguro'].sum()
etiquetas = fuma_seg_pc.index
colors = sns.color_palette("hls")
plt.title('Valor seguro contra fumador')
plt.pie(fuma_seg_pc, labels = etiquetas, colors = colors, autopct='%0.1f%%')
plt.show()
```


Valor seguro contra fumador



```

sns.countplot(data=df, x='region', hue='sexo', palette='hls')
plt.title('Cuento de Clientes por Región y Sexo')
plt.xlabel('Región')
plt.ylabel('Número de Clientes (Cuento)')
plt.show()

```



De estos gráficos se infiere lo siguiente:


Gráfico	Conclusión
Valor seguro contra fumador (boxplot)	El seguro es significativamente más caro para los fumadores, con una distribución de precios más alta en general (la mayoría paga entre 20.000 y 40.000).
Valor seguro contra fumador (circular)	Aunque hay más personas no fumadoras en el conjunto de datos, el valor del seguro que pagan los fumadores es casi igual al de los no fumadores. Esto indica que, a pesar de ser menos en cantidad, los fumadores representan un alto potencial económico para la venta de seguros, ya que sus pólizas suelen ser más costosas debido al mayor riesgo asociado al hábito de fumar.
Conteo de clientes por región y sexo	El número de clientes es similar entre hombres y mujeres en todas las regiones. Cundinamarca tiene el mayor conteo.

Análisis Multivariado: Se comparan las variables numéricas entre sí mediante el Mapa de Calor. La relación más cercana al valor número 1 es la edad y el índice de masa corporal con respecto al valor pagado al seguro.


```

sns.heatmap(df.corr(numeric_only=True), annot=True, cmap="BuPu")
plt.title('Mapa de calor: Relación entre variables')
plt.show()


```




Relación de valor seguro, rango de edad e IMC: Los valores más altos pagados corresponden a todos los rangos de edad con un índice de masa corporal alto.



Relación de valor seguro, rango de edad y fumador: En cualquier rango de edad, el hecho de que sea fumador es determinante para el pago del valor del seguro.




Relación de valor seguro, región y fumador: El hábito de fumar incrementa notablemente el costo del seguro, sin importar la región.



Relación de valor seguro, IMC y fumador: Fumar es el factor que más incrementa el costo del seguro, pero el valor es más alto para los clientes con IMC entre 30 y 35.

```
sns.relplot(data=df, x="imc", y="valor_seguro", hue="fumador", palette = sns.color_palette("hls"))
plt.title('Relación entre IMC, Valor del Seguro y Estado Fumador')
plt.xlabel('IMC')
plt.ylabel('Valor Seguro')
```


C:\Users\USER\AppData\Local\Temp\ipykernel_220496\1736931710.py:1: UserWarning: The palette list has more than 256 entries, which may cause a slowdown in rendering.
 sns.relplot(data=df, x="imc", y="valor_seguro", hue="fumador", palette = sns.color_palette("hls"))



Relación de valor seguro, sexo y fumador: Tanto hombres como mujeres fumadoras presentan valores significativamente más altos que los no fumadores.

```
sns.boxplot(x=df["sexo"], y=df["valor_seguro"], hue = df["fumador"], palette = sns.color_palette("hls"))
plt.title('Valor seguro por sexo con indicador de fumador')
plt.xlabel('Sexo')
plt.ylabel('Valor Seguro')
```

C:\Users\USER\AppData\Local\Temp\ipykernel_220496\3741249527.py:1: UserWarning: The palette list has more than 256 entries, which may cause a slowdown in rendering.
 sns.boxplot(x=df["sexo"], y=df["valor_seguro"], hue = df["fumador"], palette = sns.color_palette("hls"))



Conclusiones

El análisis detallado muestra que los valores más altos del seguro se concentran principalmente en las personas fumadoras. Este grupo paga sumas considerablemente superiores a las de los no fumadores, sin importar el sexo o la región, lo que evidencia que representan el mayor potencial comercial. La relación entre el IMC y el valor del seguro también muestra un aumento significativo del costo a medida que el IMC se incrementa, especialmente en fumadores, reforzando el peso de este factor de riesgo. En cuanto a la edad, los mayores ingresos se encuentran entre los 38 y 58 años, un segmento que debería considerarse prioritario dentro de las estrategias comerciales. Finalmente, aunque el hábito de fumar influye más que la ubicación geográfica, Cundinamarca sobresale como la región con mayor potencial al agrupar más clientes y mayores valores de seguro. En conjunto, estos hallazgos delinean un perfil claro del cliente más rentable: adultos de mediana edad, con IMC elevado y particularmente fumadores.